Taula de contingut

Format d´entrega

Aquest document s´ha realitzat mitjançant **Markdown**[1] amb l´ajuda de l´entorn de desenvolupament **RStudio**[2] utilitzant les característiques que aquest ofereix per a la creació de documents **R** reproduïbles.

La documentació generada en la realització de la pràctica es troba allotjada en **GitHub** al següent repositori:

- **https://github.com/rsanchezs/data-minig**

En aquest repositori es poden trobar els següents fitxers:

- Aquest document en formats **pdf** i **docx** amb el nom rsanchezs_practica.
- Un document **R Markdown**[3] que es pot utilitzar per a reproduir tots els exemples presentats a la PAC.
- El conjunt de dades utilitzades.

[1] **https://es.wikipedia.org/wiki/Markdown**

[2] **https://www.rstudio.com/**

[3] **https://rmarkdown.rstudio.com/**

Nota: Propietat intel·lectual

Sovint és inevitable, al produir una obra multimèdia, fer ús de recursos creats per terceres persones. És per tant comprensible fer-lo en el marc d'una pràctica dels Estudis, sempre que això es documenti clarament i no suposi plagi en la pràctica.

Per tant, al presentar una pràctica que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en que es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL ...). L'estudiant haurà d'assegurar-se que la llicència no impedeix específicament el seu ús en el marc de la pràctica. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida per copyright. Hauríeu a més, d'adjuntar els fitxers originals quan les obres utilitzades siguin digitals, i el seu codi font si correspon

Un altre punt a considerar és que qualsevol pràctica que faci ús de recursos protegits pel copyright no podrà en cap cas publicar-se en Mosaic, la revista del Graduat en Multimèdia de la UOC, llevat que els propietaris dels drets intel·lectuals donin la seva autorització explícita

PART I Preparació de les Dades

Definició de la tasca de mineria de dades

Aquesta pràctica tracta de plantejar com podria ser un projecte real de mineria de dades. Com a analistes de dades a partir de la presentació del client que exposa un problema de negoci difús i molt genèric haurem de reconduir-lo com a projecte de mineria de dades.

El client ens proporciona un conjunt de dades extretes del seu ERP, format per les següent taules: `cabeceraticket`, `client`, `familia`, `lineasticket`, `pais`, `pedido`, `producto`, `promocion`, `proveedor`, `regiongeografica`, `seccion`, `subfamilia`, `tienda`.

Els objectius principals del projecte de mineria de dades seran els següents:

En primer lloc, com què tenim poca informació del domini i volem començar a tenir-ne una idea més clara, intentarem **trobar similituds i agrupar objectes semblants**.

En segon lloc, a partir de la situació més informada obtinguda en el pas anterior, tractarem de **classificar els objectes**. El que es vol és estudiar millor les diferències entre grups i les seves característiques peculiars.

PRIMER OBJECTIU

Trobar grups de clients semblants.

SEGON OBJECTIU

Un cop separats els clients en diversos grups, volem saber quin és l´atribut que distingueix millor un grup de clients o l´altre.

Pre-processament de les Dades

Carrega i exàmen preliminar del conjunt de dades

En primer lloc, instal.larem el paquet `readr`[4] que forma part del ecosistema `tidyverse`[5] i que ens permetrà llegir les dades:

```
# La forma més sencilla de instal.lar readr es instal.lar tidyverse
install.packages("tidyverse")

# Alternativament, podem instal.lar només readr
install.packages("readr")
```

Un cop instal.lat el paquet el carregarem a la sessió R mitjançant la següent línia de codi:

```
# Carrega de readr
library(readr)

# Alternativament, com que forma part de tidyverse
library(tidyverse)
```

Observem que, hem fet ús de la segona opció que carrega tots els paquets de `tidyverse`, ja que utilitzarem per a la realització de la pràctica altres paquets, com per exemple: `dplyr` (per a la transformació de dades),`tibble` (per a un tractament més refinat de `data.frames`), `ggplot2` (per a la visualització de les dades), etc.

[4] Paquet per a la lectura de dades amb format rectangular: **https://readr.tidyverse.org/**

[5] Conjunt de paquets R per a la Ciència de les Dades :**https://www.tidyverse.org/**

Un cop carregat el paquet a la sessió R, ja podem fer ús de les funcions. Per a importar les dades dels clients i els seus ticket de compra utilitzarem la funció `read_csv()` de la següent manera:

```
# Carreguem la llibreria que ens permet importar arxius CSV
if (!require("readr")) {
  # Instal.lació de la llibreria
install.packages("readr")
# Carreguem la llibreria
library(readr)
}
client <- read_csv("data/gourmetdb/cliente.csv",
                   col_names = FALSE)
ticket <- library(readr)
ticket <- read_csv("data/gourmetdb/cabeceraticket.cvs",
                   col_names = FALSE)
```

Convertim el conjunt de dades `client` que és del tipus `data.frame` a `tibble`:

```
# Convertim el dataframe a tibble
as_tibble(client)
```

```
## # A tibble: 4,069 x 12
##    X1    X2    X3        X4 X5    X6    X7       X8 X9    X10    X11   X12
##    <chr> <chr> <chr>  <int> <chr> <chr> <chr> <int> <chr> <ch> <int> <int>
##  1 0000~ Roca~ Homb~ 1.96e7 Solt~ Piaz~ Econ~     0 Sur ~ Esp~     4     7
##  2 0065~ Fuen~ Mujer 1.94e7 Casa~ C/ N~ Inge~     1 Sur ~ Esp~    16    13
##  3 0065~ Prat~ Homb~ 1.94e7 Casa~ cors~ Doct~     2 Sur ~ Esp~    14    10
##  4 0000~ Jone~ Homb~ 1.91e7 Solt~ 1 Pl~ Inge~     0 Nort~ Rei~     2     9
##  5 0000~ Burt~ Homb~ 1.94e7 Casa~ 46 S~ Doct~     2 Nort~ Rei~    13     9
##  6 0065~ Sale~ Mujer 1.94e7 Casa~ Leop~ Econ~     1 Nort~ Rei~     7    11
##  7 0065~ Crui~ Homb~ 1.96e7 Solt~ 2 Re~ Inge~     0 Nort~ Rei~    10    12
##  8 0131~ Cole~ Homb~ 1.94e7 Casa~ 67 E~ Doct~     0 Nort~ Est~     2     6
##  9 0131~ Shav~ Mujer 1.96e7 Casa~ 432 ~ Econ~     3 Nort~ Est~    21    15
## 10 0196~ Mill~ Homb~ 1.94e7 Divo~ 68 A~ Econ~     0 Nort~ Rei~     5     9
## # ... with 4,059 more rows
```

Podem adonar-nos que, el conjunt de dades està format per 4.069 observacions i 12 variables. A més, amb l´ajuda de `tibble` també podem observar el tipus per a cada columna.

Com que el nom de les columnes es poc descriptiu per alguns dels atributs, personalitzarem els noms mitjançant la següent línia de codi:

```
# Noms dels atributs
names(client) <- c("CODCLIENT", "NOMCLIENT", "GENERE", "DATANAIXEMENT", "ESTATCIVIL
",
                   "DIRECCIO", "PROFESSIO", "NROFILLS", "REGIO",
                   "NACIONALITAT","TOTALCOMPRES","PUNTSACUMULATS")
names(ticket) <- c("CODVENTA", "NOMTENDA", "DATA", "HORA", "FORMAPAGAMENT",
                   "CODCLIENT", "TOTALIMPORT", "TOTALUNITATS", "PUNTSTICKET")
```

Podem comprovar el nom de les columnes mitjançant la funció `colnames`:

```
# Comprovem es nom de les columnes
colnames(client)

##  [1] "CODCLIENT"      "NOMCLIENT"      "GENERE"         "DATANAIXEMENT"
##  [5] "ESTATCIVIL"     "DIRECCIO"       "PROFESSIO"      "NROFILLS"
##  [9] "REGIO"          "NACIONALITAT"   "TOTALCOMPRES"   "PUNTSACUMULATS"

# Comprovem es nom de les columnes
colnames(ticket)

## [1] "CODVENTA"      "NOMTENDA"      "DATA"          "HORA"
## [5] "FORMAPAGAMENT" "CODCLIENT"     "TOTALIMPORT"   "TOTALUNITATS"
## [9] "PUNTSTICKET"
```

Exploració i tractament de valors desconeguts

Per altra banda, ens caldria comprovar que el nostre conjunt de dades no conté valors desconeguts. En primer lloc comprovem el conjunt de dades client:

```
# Estadístiques de valors buits client
colSums(is.na(client))

##      CODCLIENT      NOMCLIENT         GENERE  DATANAIXEMENT     ESTATCIVIL
##              0              0              0              0            805
##       DIRECCIO      PROFESSIO       NROFILLS         REGIO   NACIONALITAT
```

```
##              0              0            805              0              0
##   TOTALCOMPRES PUNTSACUMULATS
##              0              0
```

Com es pot observar la variable `estatcivil` conté 805 observacions amb valors desconeguts. Amb l´objectiu de fer aquest grup més descriptiu podríem canviar aquests valors per la constant `Desconegut`:

```
# Amb l´ajuda de un test lògic descobrim els valors desconeguts
missing_values_estat_civil <- is.na(client$ESTATCIVIL)
# Reemplacem els valors desconeguts amb la  constant
client$ESTATCIVIL[missing_values_estat_civil] <- "Desconegut"
```

A més, fixe-mos que la variable `nombrefills` també conté 805 observacions amb valors desconeguts. En aquest cas, reemplaçarem els valor desconeguts amb un valor aleatori de la distribució de la variable. Em primer lloc, amb l´ajuda d´un test lógic descobrim els valors desconeguts:

```
# Amb l´ajuda de un test lògic descobrim els valors desconeguts
missing_values_nombrefills <- is.na(client$NROFILLS)
```

A continuació, generem un valor aleatori de la distribució de la variable:

```
# Generem observacions aleàtories
random_nombrefills_obs <- sample(na.omit(client$NROFILLS), 1)
random_nombrefills_obs
```

```
## [1] 2
```

Finalment, reemplacem els valors desconeguts amb el valor aleatori calculat en en fragment de codi anterior:

```
# Reemplacem els valors desconeguts amb la observació aleàtoria

client$NROFILLS[missing_values_nombrefills] <-random_nombrefills_obs
```

Pel que fa al conjunt de dades `ticket` realitzarem les mateixes tasques que hem realitzat amb els clients. Així començarem comprovant que no tinguem dades desconegudes:

```
# Estadístiques de valors buits tickets
colSums(is.na(ticket))
```

```
##      CODVENTA      NOMTENDA          DATA          HORA FORMAPAGAMENT
##             0             0             0             0             0
##     CODCLIENT   TOTALIMPORT  TOTALUNITATS   PUNTSTICKET
##         38810             0             0             0
```

Com es pot comprobar a l´anterior fragment de codi el conjunt de dades `ticket` no conté cap valor buit o desconegut per a cap de les seus variables.

Transformació d´atributs

L´objectiu principal d´aquest apartat es realitzar tasques de transformació en les variables del nostre conjunt de dades.

Per a facilitar l´ànalisi sería convenient canviar els atributs de tipus `character` a `factor`, que és la manera que té R de tractar amb les variables de tipus categòric:

```
# Carreguem ecosistema tidyverse
if (!require("tidyverse")) {
  # Instal.lació de la llibreria
install.packages("tidyverse")
# Carreguem la llibreria
library(tidyverse)
}
# Canviem les variables de tipus `character` a `factor`
cols <- c('CODCLIENT', 'NOMCLIENT', 'GENERE', 'ESTATCIVIL', 'DIRECCIO',
```

```
          'PROFESSIO', 'REGIO', 'NACIONALITAT')
client <- mutate_at(client, cols, as.factor)
```

De la mateixa manera, ens caldrà fer igual amb les variables de tipus `charater` en el conjunt de dades `ticket`:

```
# Canviem les variables de tipus `character` a `factor`
cols <- c('CODVENTA', 'NOMTENDA', 'FORMAPAGAMENT', 'CODCLIENT')
ticket <- mutate_at(ticket, cols, as.factor)
```

Fixe-mos amb el codi anterior que amb l´ajuda de la funció `dplyr::mutate_at`[6] hem canviat les columnes de tipus `character` al tipus `factor`.

Amb el següent fragment de codi i amb l´ajuda de la funció `lapply()` verifiquem que s´han produït els canvis. Per exemple, comprovem-ho amb el conjunt de dades `client`:

```
# Retorna el tipus de cada variable
lapply(client, class)
```

```
## $CODCLIENT
## [1] "factor"
##
## $NOMCLIENT
## [1] "factor"
##
## $GENERE
## [1] "factor"
##
## $DATANAIXEMENT
## [1] "integer"
##
## $ESTATCIVIL
## [1] "factor"
##
```

[6] La notació `paquet::nom_funció` s´utilitza per a indicar a R que es vol fer ús de la funció del paquet indicat, en el cas que existeixi ambigüitat amb el nom d´una funció en un altre paquet.

```
## $DIRECCIO
## [1] "factor"
##
## $PROFESSIO
## [1] "factor"
##
## $NROFILLS
## [1] "integer"
##
## $REGIO
## [1] "factor"
##
## $NACIONALITAT
## [1] "factor"
##
## $TOTALCOMPRES
## [1] "integer"
##
## $PUNTSACUMULATS
## [1] "integer"
```

Cal fer esment específic que sería pràctic convertir la variable `naixement` del tipus `numeric` a `date`:

```
# Carreguem lubridate per al tractament de dades de tipus date
if (!require("lubridate")) {
  # Instal.lació de la llibreria
install.packages("lubridate")
# Carreguem la llibreria
library(lubridate)
}
# Convertim la variable naixement a tipus date
client <- client %>% mutate_at("DATANAIXEMENT", funs(ymd))
```

Gràcies a l´anterior canvi de tipus podem calcular l´edat del client de la següent manera:

```
# Carreguem ecosistema tidyverse
if (!require("tidyverse")) {
  # Instal.lació de la llibreria
install.packages("tidyverse")
# Carreguem la llibreria
```

```
library(tidyverse)
}
client <- client %>%
        mutate(EDAT = year(Sys.Date()) - year(client$DATANAIXEMENT))
```

Realitzem un resúm estadístic de la variable `EDAT`:

```
# Resúm estadístic
summary(client$EDAT)

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   40.00   52.00   68.00   67.37   80.00  109.00
```

Fixe-mos que el rang està comprés entre 40 i 109 anys, sembla que la edat estigui mal calculada. Si analitzem com hem calculat la edat anteriorment podem comprovar que els calculs són correctes, ja que hem realitzat la diferencia de la data actual amb la data de naixement.

En conseqüència, ens fa pensar que el conjunt de dades de la base de dades `GourmetBD` està format per valors pretèrits. Per aquest motiu, anem a calcular de nou la variable `EDAT` però en aquest cas utilitzamen com a any en curs el 1992:

```
# Calculem la edat client utilitzant com a any en curs 1992
client <- client %>%
        mutate(EDAT = 1992 - year(client$DATANAIXEMENT))
```

Concretament, després de realitzar els nous calculs podem comprovar que el rang està entre 13 i 82:

```
range(client$EDAT)

## [1] 13 82
```

En un altre ordre de coses, crearem un nou conjunt de dades que es tractara de la consulta **left-join** de les taules `client` i `ticket` que estan relacionades a la fase de dades per la clau forana `CODCLIENT`:

```
# Selecciona les observacions que apareixen almenys en una de les taules
# cpnservant totes les observacions de ticket
tickets_client <- left_join(client, ticket, by = "CODCLIENT")
```

A continuació, crearem una nova columna amb la suma dels imports totals dels tickets per a cada client. Es a dir, agruparem les observaciones per client i calcularem una nova variable amg la funció d´agregació `sum()`:

```
# Agrupem per client i realitzem la suma del import de cada ticket
import_total_tickets_client <- tickets_client %>%
                          group_by(CODCLIENT) %>%
                          summarise(TOTAL = sum(TOTALIMPORT))
```

Al següent fragment de codi afegim la variable creada anteriorment al conjunt de dades `tickets_client`:

```
tickets_client <- tickets_client %>% select(-CODVENTA, -DATA,
                                             -HORA, -FORMAPAGAMENT,
                                             -TOTALIMPORT, -TOTALUNITATS,
                                             -PUNTSTICKET) %>%
                          group_by(CODCLIENT) %>%
                          na.omit(.) %>%
                          distinct(.) %>%
                          left_join(import_total_tickets_client,
                                    by = "CODCLIENT")
```

Com hem anteriorment sería convenient canviar els atributs de tipus `character` a `factor`, que és la manera que té R de tractar amb les variables de tipus categòric:

```
# Carreguem ecosistema tidyverse
if (!require("tidyverse")) {
  # Instal.lació de la llibreria
install.packages("tidyverse")
# Carreguem la llibreria
library(tidyverse)
}
```

```
# Canviem les variables de tipus `character` a `factor`
cols <- c('CODCLIENT', 'NOMCLIENT', 'GENERE', 'ESTATCIVIL', 'DIRECCIO',
          'PROFESSIO', 'REGIO', 'NACIONALITAT')
client <- mutate_at(client, cols, as.factor)
```

Reducció de la Dimensionalitat

Per a la simplificació de l´anàlisi les següents variables són descartades:

```
# Reducció de la dimensionalitat
#tickets_client$CODCLIENT <- NULL
tickets_client$NOMCLIENT <- NULL
tickets_client$DIRECCIO <- NULL
tickets_client$DATANAIXEMENT <- NULL
```

Els motius són els següents:

- La variable `codi` representa la clau primaria en la base de dades i no ens proporcionará informació per a estudiar millor les diferències entre grups.

- La variable `nom` pot ser el.liminada pel fet que, es tracta del nom del individu i que té funcions de particularització o individualització i no ens serveix per a les tasques d´agrupació i classificació.
- La variable `direccio` es tracta de la direcció del domicili del client i no ens proporciona informació rellevant per a la nostra anàlisi. En canvi, les variables `regio` i `nacionalitat` són atributs més adequats per al nostre proposit.
- La variable `naixement` pot ser el.liminada, ja que representa la data de naixement del client i no proporciona informació per al nostre model. No obstant, la edat del client es una característica peculiar i es pot estimar a partir de la data de naixement i la data actual. Aquest atribut ja ha sigut calculat i representat amb la variable `edat`.

Recollint tot el que s´ha realitzat, tenim 11 atributs per a la nostra anàlisi i 2923 observacions en el conjunt de dades `client`:

```
# Obtenim el nom de les variables
colnames(tickets_client)
```

```
##  [1] "CODCLIENT"      "GENERE"         "ESTATCIVIL"     "PROFESSIO"
##  [5] "NROFILLS"       "REGIO"          "NACIONALITAT"   "TOTALCOMPRES"
##  [9] "PUNTSACUMULATS" "EDAT"           "NOMTENDA"       "TOTAL"
```

```
# Obtenim la dimensió
dim(tickets_client)
```

```
## [1] 3923   12
```

Identificació de *outliers*

Transformació de les Dades

Per a la *normalització* del conjunt de dades `tickets_client` utilitzarem el **mètode d´estandardització de valors** assegurant-nos que s´obtenen valors dins el rang escollit que tenen la propietat que la seva mitjana és zero i la seva desviacióestàndard val 1.

Es a dir, l´estandardització consisteix en la diferència entre el valor de l´atribut i la seva mitjana, dividint aquesta diferència per la desviació estàndard dels valors de l´atribut. Es a dir:

$$Z - score \quad = \quad \frac{X \quad - \quad mean(X)}{SD(X)}$$

En el següent fragment discretitzarem les variables `NROFILLS`, `PUNTSACUMULATS`, `EDAT` i `TOTAL`estandaritzant-les amb l´ajuda de la funció `scale()`:

```
tickets_client <- tickets_client %>% mutate_at(vars(NROFILLS, TOTALCOMPRES
                                                    PUNTSACUMULATS, EDAT
                                                    TOTAL),
                                                    funs(scale(.)))
```

A banda d´això, per a facilitar el nostre anàlisi i en concret l´anàlisi exploratori de les dades, realitzarem una segmentació dels nostres clients respecte la freqüència de compra.

Així, realitzarem una discretització utilitzant l´atribut `TOTALCOMPRES` que pren els valors entre 1 i 48 dividint els valors entre els conjunts: **FREQUENTE**, **HABITUAL** i **OCASIONAL**.

En primer lloc, hem de calcular la distribució de freqüencies absolutes de la variable `TOTALCOMPRES`:

```
total_compres <- tickets_client$TOTALCOMPRES
breaks <- seq(1, 48, by = 5)
total_compres_cut <- cut(total_compres, breaks, by = 5, right = FALSE)
total_compres_freq <- table(total_compres_cut)
```

Amb la funció `nrow()` podem trobar la freqüencia total n del conjunt de dades, així podem realitzar el cocient de les freqüencies absolutes per n. De manera que, la **distribució de freqüencies relatives** es:

```
# Càlcul distribució freqüencies relatives total compres per client
total_compres_relfreq <- total_compres_freq / nrow(tickets_client)
cbind(total_compres_freq, total_compres_relfreq)
```

```
##         total_compres_freq total_compres_relfreq
## [1,6)                 1183           0.301554932
## [6,11)                1470           0.374713230
## [11,16)                786           0.200356870
## [16,21)                300           0.076472088
## [21,26)                105           0.026765231
## [26,31)                 49           0.012490441
## [31,36)                 20           0.005098139
## [36,41)                  7           0.001784349
## [41,46)                  1           0.000254907
```

Finalment, creem una nova variable que classificarà els nostres clients segons la freqüencia de compra:

```
tickets_client <- tickets_client %>%
        mutate(FREQCOMPRA = case_when(between(TOTALCOMPRES, 1, 5) ~ "OCASIONAL",
                                      between(TOTALCOMPRES, 6, 21) ~ "FRECUENTE",
                                      between(TOTALCOMPRES, 22, 48) ~ "HABITUAL" ))
```

Anàlisi Exploratori de les Dades

En primer lloc, passem a estudiar la variable `GENERE` respecte a `FREQCOMPRA`. Per tal d´explorar la relació entre aquestes variables realitzarem les següents operacions:

- Agrupar el conjunt de dades per la variable `GENERE`.
- Contar el nombre d´observacions de la variable `FREQCOMPRA` que apareixen en cada classe del atribut `GENERE`.
- Calcular el percentatge en cada classe segons la variable `FREQCOMPRA`.

Totes aquestes operacions queden simplificades amb l´ajuda de les funcions `group_by` i `count` del paquet `dplyr`, i de l´operador `%>%`:

```
# Gràfic barra genere vs freqüència compra
tickets_client %>%
  group_by(GENERE) %>%
   count(FREQCOMPRA) %>%
    mutate(freq = round(n / sum(n) * 100, 0)) %>%
    ggplot(mapping = aes(x = GENERE, y = n, fill = FREQCOMPRA)) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste(freq, "%"))) +
    theme(axis.text.x = element_text (size = 10, angle=45))
```

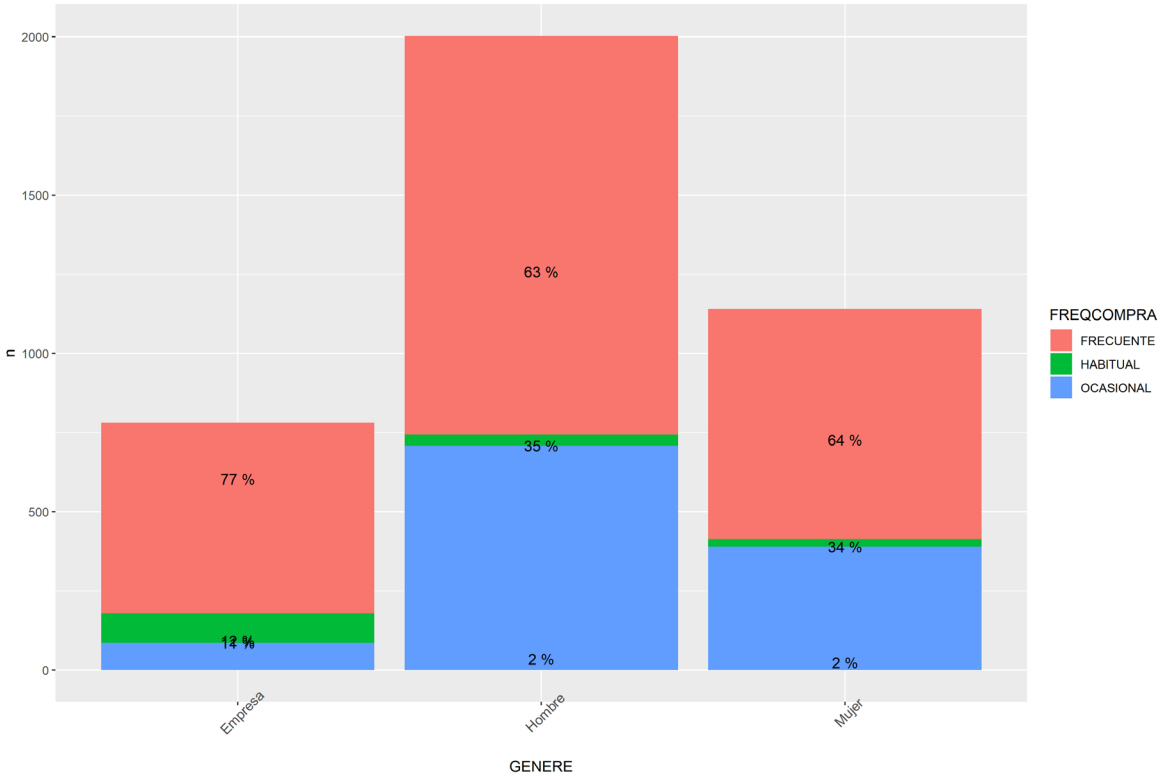

És a saber, que obtenim els mateixos resultats que al gràfic anterior però en format de resúm amb el següent codi:

```
# Resúm de les dades
tickets_client %>%
  group_by(GENERE) %>%
  count(FREQCOMPRA) %>%
  mutate(FREQ = round(n / sum(n) * 100, 0))
```

```
## # A tibble: 9 x 4
## # Groups:   GENERE [3]
##   GENERE  FREQCOMPRA     n  FREQ
##   <fct>   <chr>      <int> <dbl>
## 1 Empresa FRECUENTE    603    77
## 2 Empresa HABITUAL      93    12
## 3 Empresa OCASIONAL     85    11
## 4 Hombre  FRECUENTE   1258    63
## 5 Hombre  HABITUAL      35     2
## 6 Hombre  OCASIONAL    709    35
```

```
## 7 Mujer    FRECUENTE    727    64
## 8 Mujer    HABITUAL      24     2
## 9 Mujer    OCASIONAL    389    34
```

En segon lloc, estudiarem la variable `ESTATCIVIL`. Realitzant els mateixos passos que en el apartat anterior obtenim el següent diagrama de barres apilat:

```
# Gràfic barra estat civil vs freqüència de compra
tickets_client %>%
  group_by(ESTATCIVIL) %>%
   count(FREQCOMPRA) %>%
    mutate(freq = round(n / sum(n) * 100, 0)) %>%
    ggplot(mapping = aes(x = ESTATCIVIL, y = n, fill = FREQCOMPRA)) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste(freq, "%"))) +
    theme(axis.text.x = element_text (size = 14, angle=45))
```

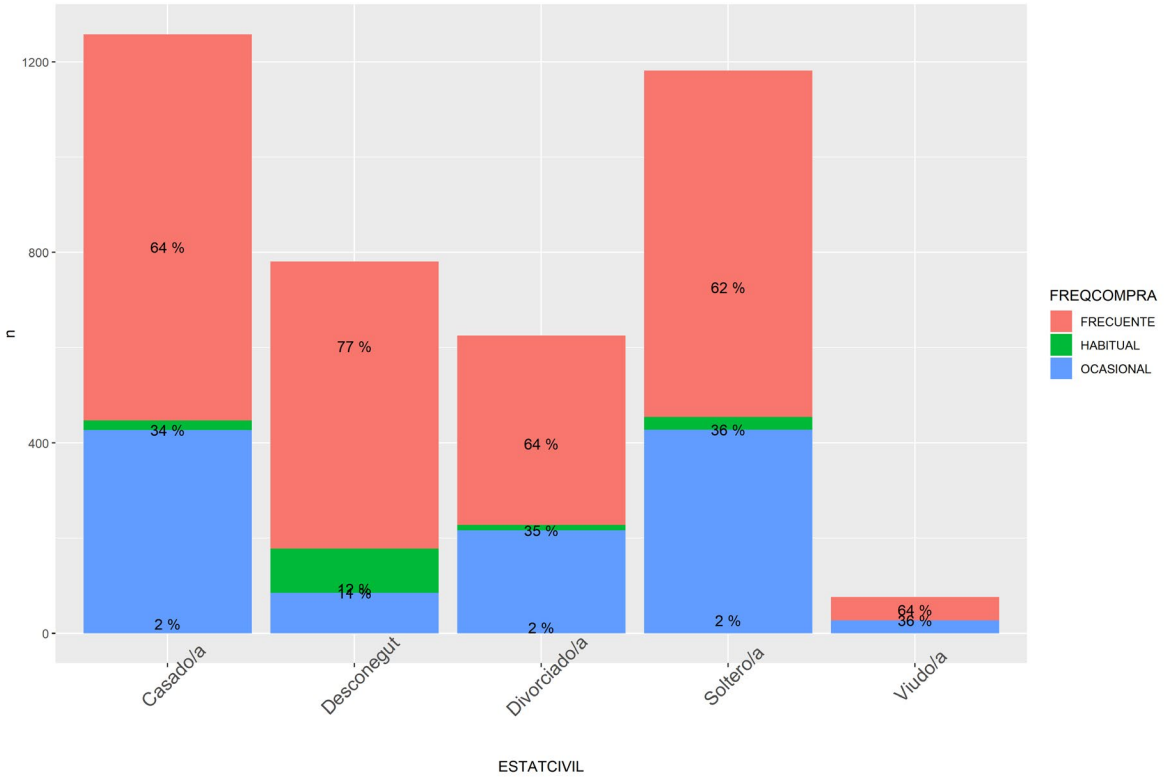

Prosseguim el nostre anàlisi amb la variable `PROFESSIO`. Igual com hem fet anteriorment obtenim el següent diagrama de barres:

```
# Gràfic barra professió vs freqüència de compra
tickets_client %>%
  group_by(PROFESSIO) %>%
   count(FREQCOMPRA) %>%
    mutate(freq = round(n / sum(n) * 100, 0)) %>%
    ggplot(mapping = aes(x = PROFESSIO, y = n, fill = FREQCOMPRA)) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste(freq, "%"))) +
    theme(axis.text.x = element_text (size = 14, angle=90))
```

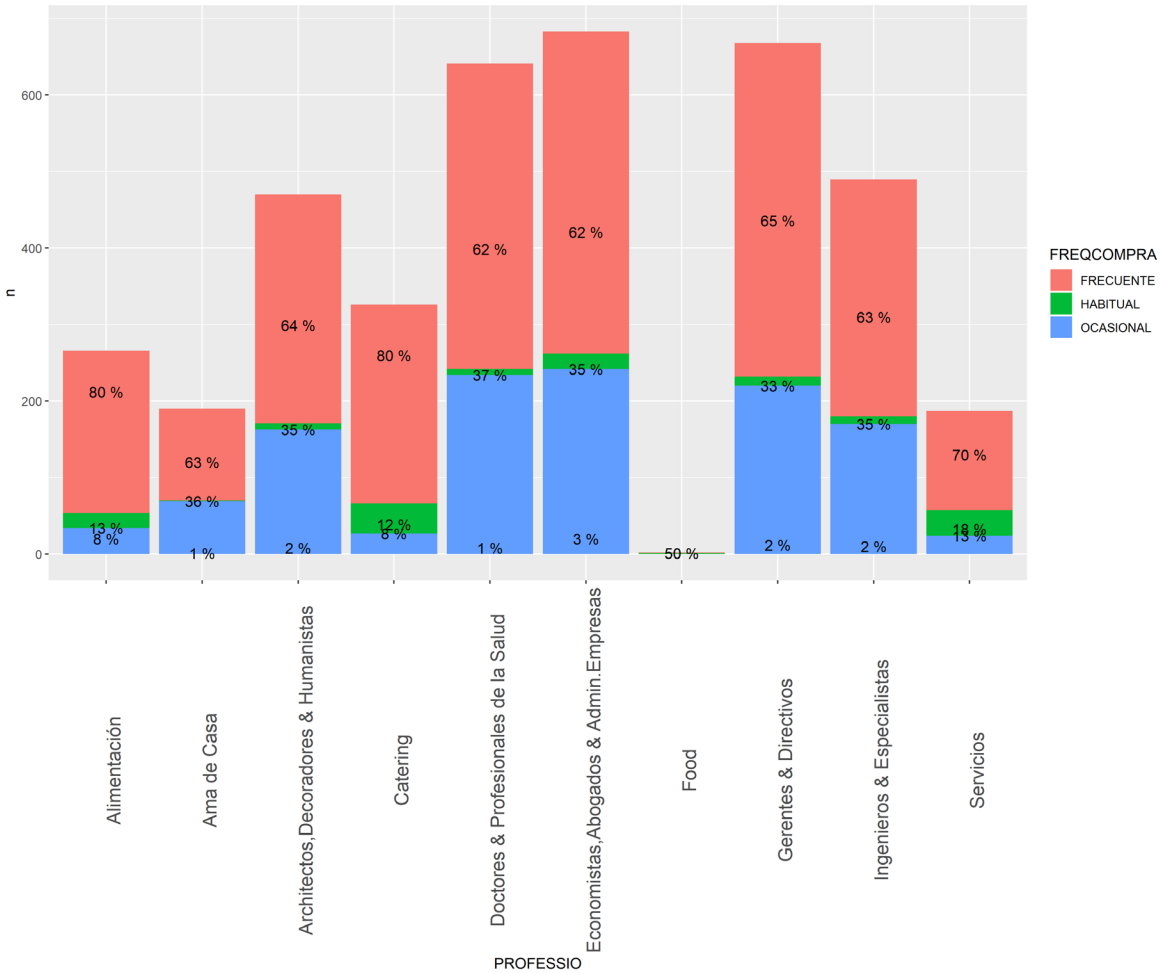

Avançant en el nostre anàlisi exploratori , passem a examinar la covariació entre les variables `REGIO` i `FREQCOMPRA`:

```
# Gràfic barra regio vs freqüència de compra
tickets_client %>%
  group_by(REGIO) %>%
   count(FREQCOMPRA) %>%
    mutate(freq = round(n / sum(n) * 100, 0)) %>%
    ggplot(mapping = aes(x = REGIO, y = n, fill = FREQCOMPRA)) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste(freq, "%"))) +
    theme(axis.text.x = element_text (size = 14, angle=45))
```

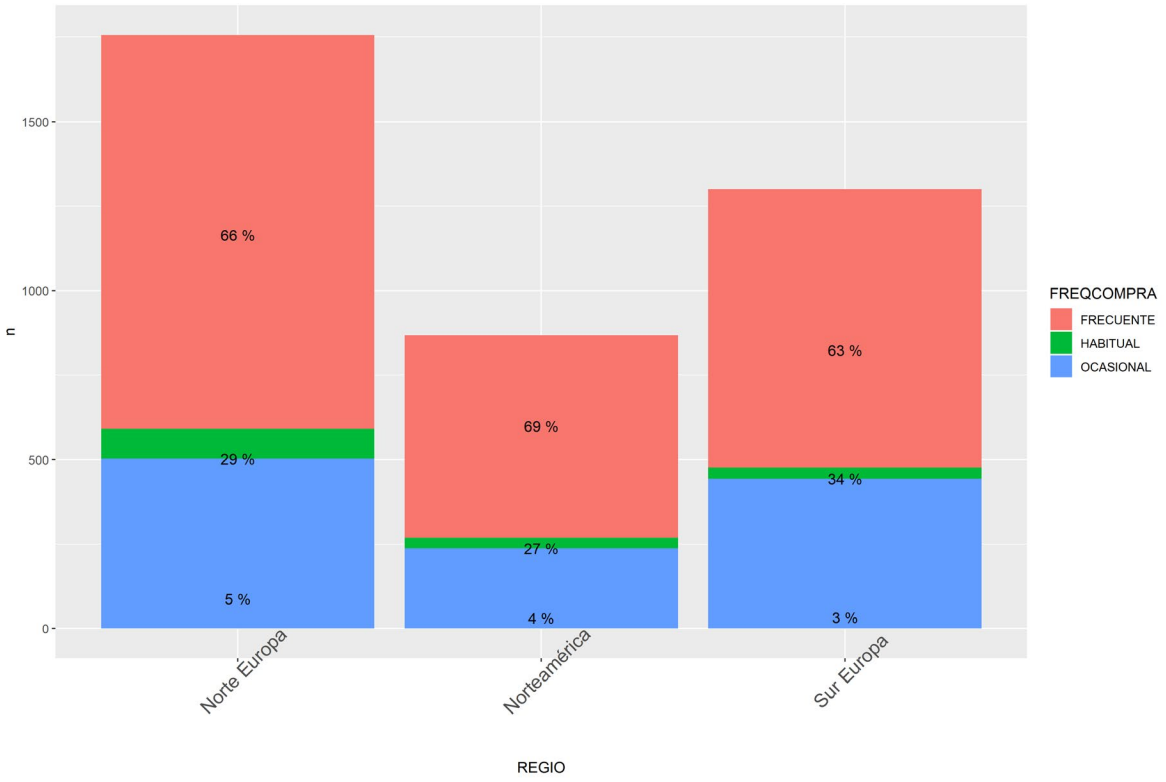

Per acabar, analitzem la variable `NACIONALITAT`. El següent fragmet de codi ens mostra una representació gràfica en diagrama de barres apilat de la variable respecte a `FREQCOMPRA`:

```
# Gràfic barra regio vs freqüència de compra
tickets_client %>%
  group_by(NACIONALITAT) %>%
   count(FREQCOMPRA) %>%
    mutate(freq = round(n / sum(n) * 100, 0)) %>%
    ggplot(mapping = aes(x = NACIONALITAT, y = n, fill = FREQCOMPRA)) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste(freq, "%"))) +
    theme(axis.text.x = element_text (size = 14, angle=45))
```

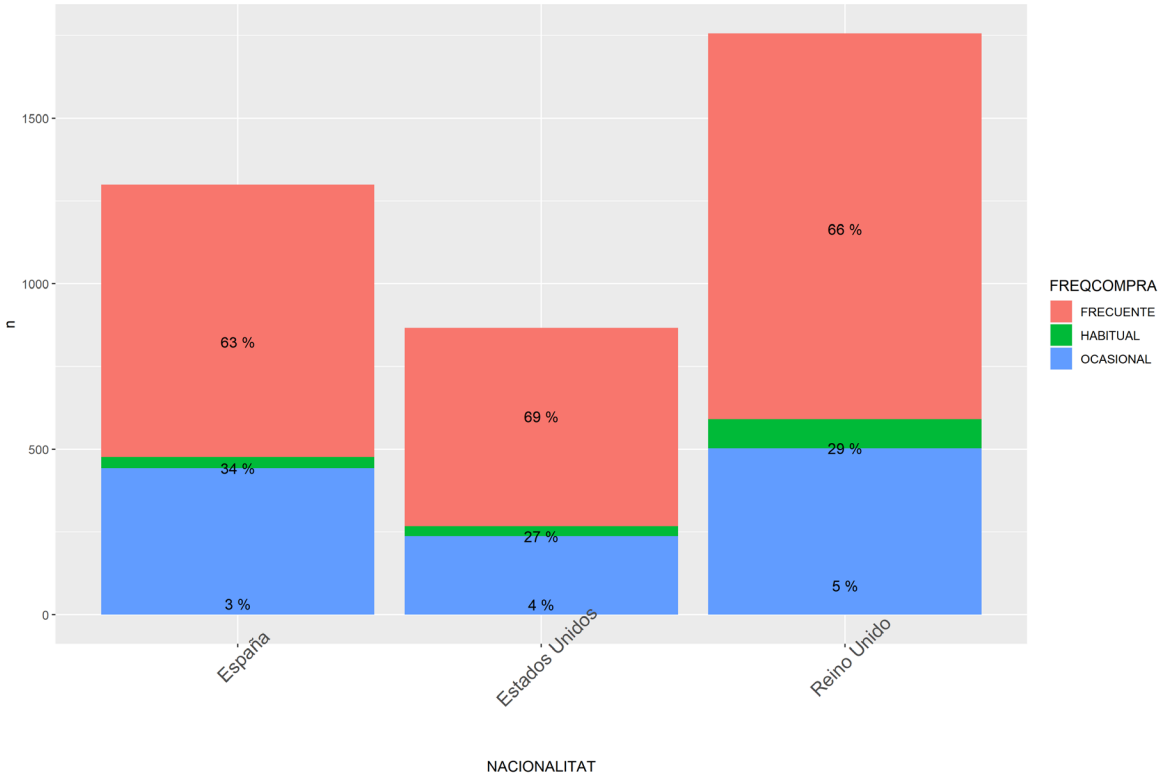

PART II Clustering

Requisits

Per començar, per a la realització del nostre anàlisi necessitarem els següents paquets:

- `cluster` per a la computació dels algoritmes d´agregació.
- `factoextra` per a la visualització de resultats d´agregació i que es fonamenta en el paquet `ggplot2`.[7]
- `clValid` que s´utilitza per a comparar els mètodes d´agregació.
- `clustertend` per avaluar estadisticament de les tendencies d´agregació.

El paquet `factoextra` conté funcions per anàlisi de *clustering* i visualització dels resultats:

Funció	Descripció
`dist(fviz_dist, get_dist)`	Visualització i computació de la matriu de distàncies
`get_clust_tendency`	Avaluació de la tendència d´agregació
`fviz_nbclust(fviz_gap_stat)`	Determinació del nombre òptim de clústers
`fviz_dend`	Visualització de dendrogrames
`fviz_cluster`	Visualització dels resultats d´agrupament
`fviz_mclust`	Visualització dels resultats del model d´agrupament
`fviz_silhouette`	Visualització de la informació de la silueta
`hkmeans`	K-means jeràrquic
`eclust`	Visualització de l´anàlisi de agrupament

[7] La documentació oficial es pot trobar a: **http://www.sthda.com/english/rpkgs/factoextra**.

Podem instal·lar els dos paquets com es mostra en la següent línia de codi:

```
# Instalació paquets clustering
install.packages(c("cluster", "factoextra", "clValid", "clustertend"))
```

En acabat, ens caldrà carregar les llibreries a la sessió R:

```
# Carreguem les llibreries
library(cluster)
library(factoextra)
library(clValid)
```

Determinació del nombre de clústers

Per a determinar el nombre de clústers farem ús de la funció `fviz_nbclust()` del paquet `factoextra` que calcula els mètodes **Elbow**, **Silhouhette** i **Gap**.

El prototip de la funció es el següent:

```
fviz_nbclust(x, FUNcluster, method = c("silhouette", "wss", "gap_stat"))
```

on els arguments són els següents:

- **x:** matriu o data frame.
- **FUNcluster:** una funció d´agregació. Valors possibles: kmeans, pam, clara i hcut.
- **method:** mètode per a determinar el nombre òptim de clústers. Valors possibles: **Elbow**, **Silhouhette** i **Gap**

Per al nostre anàlisi de la segmentació dels nostres clients utilitzarem el següent conjunt de prova:

A continuació, es mostra com determinar el nombre òptim de particions per al mètode *k-means*:

```
# Mètode elbow
fviz_nbclust(tickets, kmeans, method = "wss") +
  geom_vline(xintercept = 4, linetype = 2) +
  labs(x = "Nombre de particions k",
       y = "Total intra-clúster suma de quadrats",
       title = "Nombre òptim de particions",
       subtitle = "Mètode Elbow") +
  theme_classic() +
  theme(plot.title = element_text(color="#4F81BD", size=14, face="bold"),
        plot.subtitle = element_text(color="#4F81BD", size=14))
```

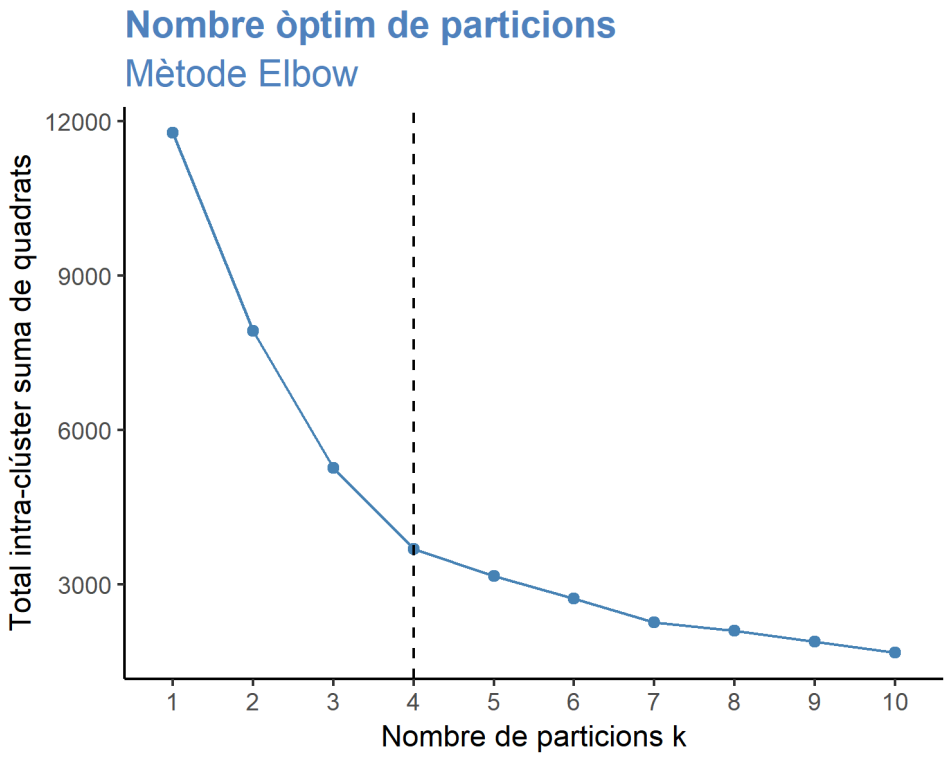

```
# Mètode Silhouette
fviz_nbclust(tickets, kmeans, method = "silhouette") +
  labs(x = "Nombre de particions k",
       y = "Ample de la mitjana de la silueta",
       title = "Nombre òptim de particions",
       subtitle = "Mètode Silhouette") +
  theme_classic() +
  theme(plot.title = element_text(color="#4F81BD", size=14, face="bold"),
        plot.subtitle = element_text(color="#4F81BD", size=14))
```

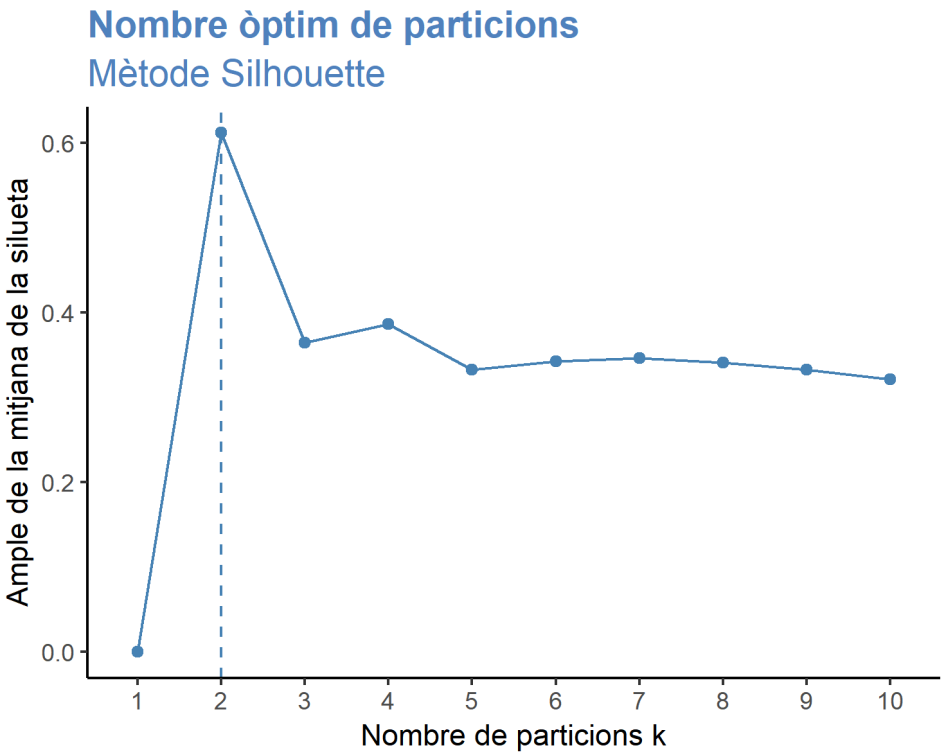


```
# Mètode Gap
set.seed(123)
fviz_nbclust(tickets, kmeans, nstart = 25,
             method = "gap_stat", nboot = 5) +
  labs(x = "Nombre de particions k",
       y = "Valor de Gap (k)",
       title = "Nombre òptim de particions",
       subtitle = "Mètode Gap") +
```

```
  theme_classic() +
  theme(plot.title = element_text(color="#4F81BD", size=14, face="bold"),
        plot.subtitle = element_text(color="#4F81BD", size=14))
```

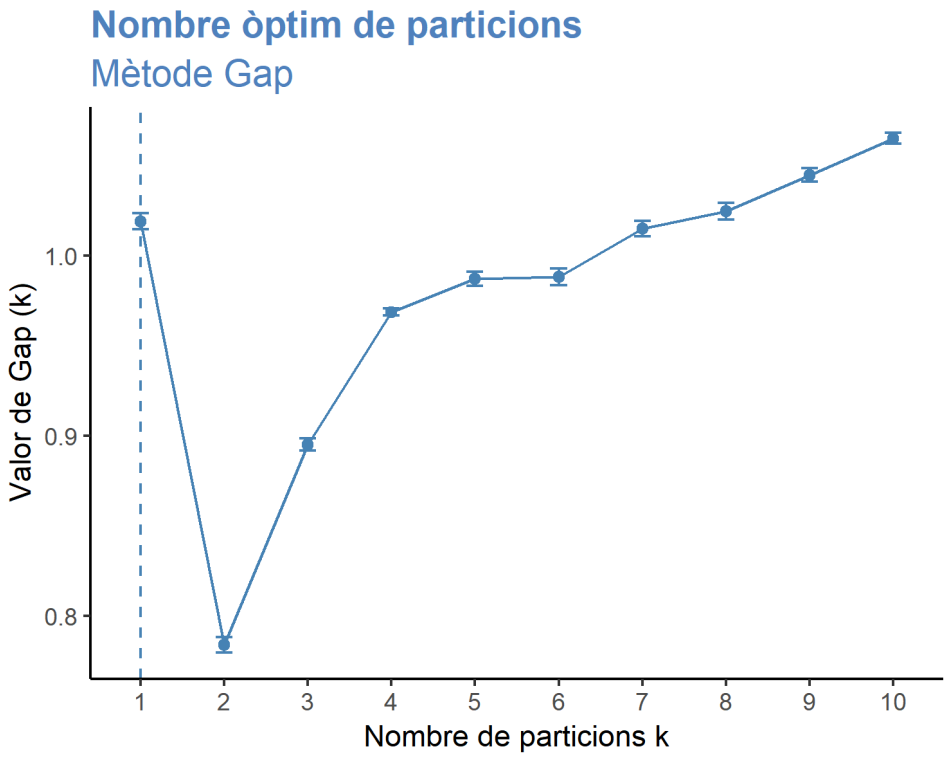

Com podem observar en els gràfics:

- El mètode Elbow ens suggereix 4 clústers.
- El mètode Silhoutte ens suggereix 2 clústers.
- El mètode Gap ens sugereix 4 clústers.

Així és que, segons aquestes observacions podem considerar $k = 4$ com el nombre òptim de clústers.

Mètode d´agregació *k-means*

A causa de que, l´algoritme *k-means* comença seleccionant un centroide aleatòriament, es recomanable fer ús de la funció `set.seed()` a l´efecte de aconseguir resultats reproduïbles. Així el lector d´aquest document obtindrà els mateixos resultats que es presenten tot seguit.

A continuació es mostra com aplicar l´algorisme k-means amb k = 4:

```
# Execució k-means amb k = 4
set.seed(123)
kmeansFit <- kmeans(tickets, 4, nstart = 25)
```

Podem mostrar per pantalla els resultats amb la següent línia de codi:

```
# Mostrem els resultats
print(kmeansFit)
```

```
## K-means clustering with 4 clusters of sizes 69, 74, 46, 7
##
## Cluster means:
##   TOTALCOMPRES       EDAT      TOTAL
## 1    -0.343604 -1.0000575 -0.2771167
## 2    -0.546290  0.8601257 -0.3153103
## 3     0.873034  0.1985773  0.2374292
## 4     3.424939 -0.5399843  4.5046100
##
## Clustering vector:
##   [1] 1 3 1 1 2 2 1 3 2 1 2 2 3 4 2 2 3 1 2 1 2 2 4 2 3 2 2 2 3 3 3 3 2 2 2
##  [36] 1 2 2 3 2 2 1 2 1 2 1 1 3 3 2 2 2 2 2 1 1 1 3 3 2 4 3 3 2 2 2 2 1 1 3
##  [71] 2 1 3 3 1 1 2 2 1 1 1 3 1 4 1 2 3 1 1 2 2 1 1 2 2 1 2 3 1 1 2 1 2 1 1
## [106] 3 3 1 3 2 2 1 3 1 2 2 2 2 3 2 1 2 4 1 3 2 3 2 3 3 1 3 1 2 1 1 3 2 2 2
## [141] 1 3 3 2 1 2 1 3 3 2 3 1 2 1 1 1 2 1 1 3 1 2 1 2 1 4 2 1 1 1 3 2 1 2 1
## [176] 2 3 4 3 1 1 2 1 1 1 1 2 3 2 3 2 3 1 2 1 3
##
```

```
## Within cluster sum of squares by cluster:
## [1] 33.40863 48.22872 40.68178 30.37939
##  (between_SS / total_SS =  73.9 %)
##
## Available components:
##
## [1] "cluster"      "centers"      "totss"        "withinss"
## [5] "tot.withinss" "betweenss"    "size"         "iter"
## [9] "ifault"
```

Podem observar en la sortida el següent:

- La mitjana de clústers: una matriu, on les files són el nombre de clúster i les columnes són les variables.
- El vector de particions: un vector d´enters (de 1:k) que indica el clúster on cada observació ha sigut agrupada.

Així mateix, és recomanable realitzar un gràfic amb els resultats del model. Ja sigui, per a escollir el nombre de clústers, ja sigui per a comparar diferents anàlisis.

Una possible opció és visualitzar les dades en un diagrama de dispersió acolorint cada observació d'acord al grup assignat.

El problema és que el nostre conjunt de dades conté més de 2 variables i no és possible representar el model en dues dimensions.

Convé fer ressaltar que, una possible solució és reduir la dimensionalitat fent ús d´un algoritme de reducció del nombre d´atributs, com per exemple **Principal Component Analysis (PCA)**.

En aquest sentit, farem ús de la funció `fviz_cluster()` que ens permetrà visualitzar els clústers i que utilitza PCA quan el nombre de variables és més gran de 2. Passarem com a arguments el resultat del model i el conjunt de dades original:

```
# Visualitzem els clústers
fviz_cluster(kmeansFit, data = tickets, stand = TRUE,
    main = "Gràfic de clústers",
    palette = c("#2E9FDF", "#00AFBB", "#E7B800", "#FC4E07"),
    ellipse.type = "euclid",
    star.plot = TRUE,
    repel = TRUE,
    ggtheme = theme_minimal()) +
  theme(legend.position = "bottom",
        plot.title = element_text(color="#4F81BD", size=16, face="bold"))
```

Gràfic de clústers

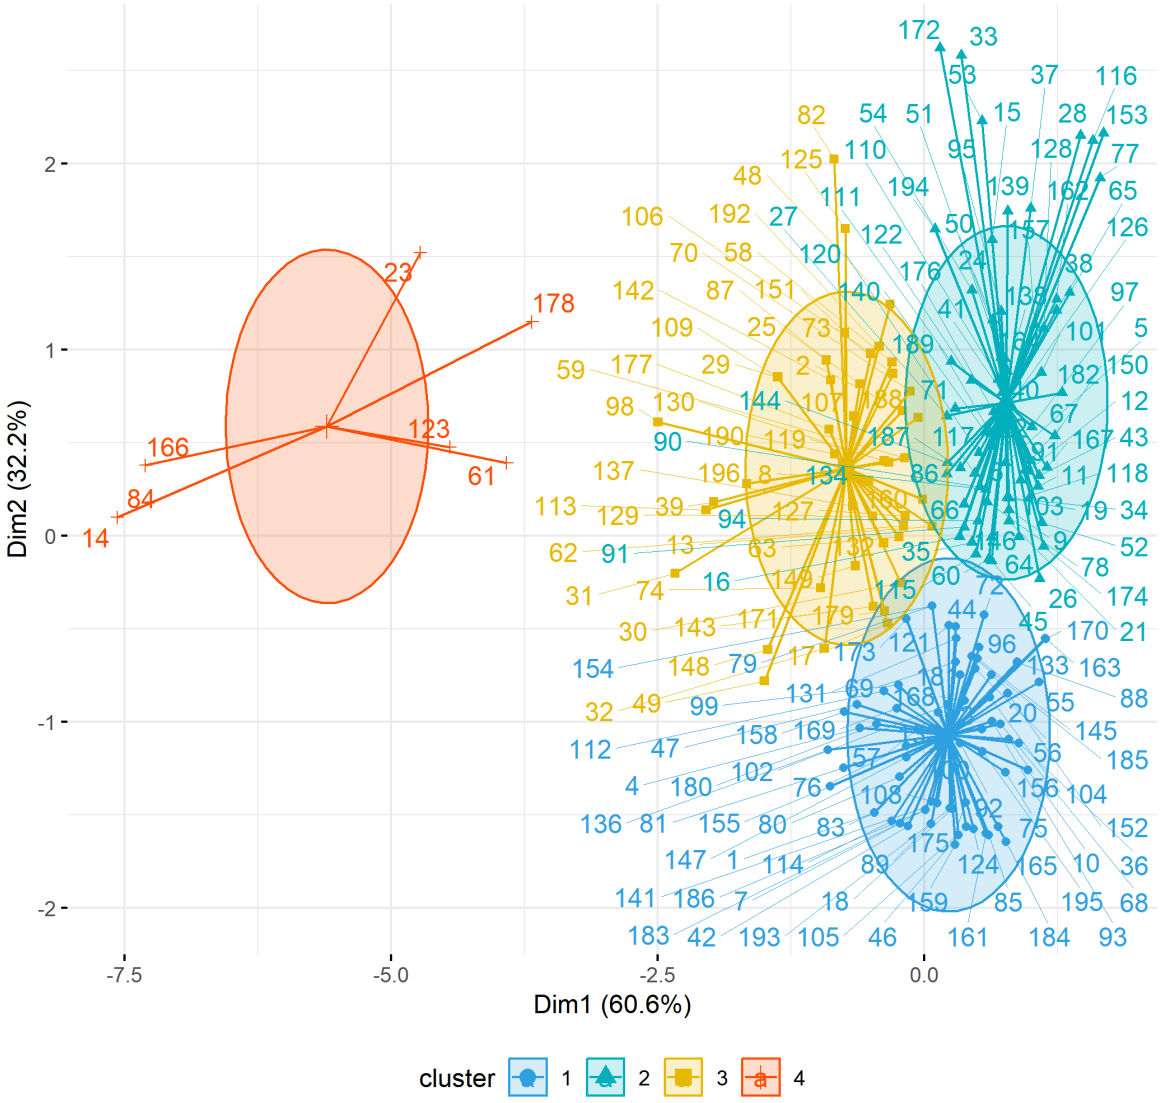

Podem observar en el gràfic que les observacions són representades mitjançant punts i que en el nostre cas s´ha usat PCA. A més, s´han dibuixat el.lipses per tal de diferenciar cada clúster.

PART III Classificació

El paquet Caret

Per a la realització del model predictiu utilitzarem el paquet `caret`[8] (acrònim per a **C** lassification **A** nd **RE** gression **T** raining). Aquest paquet es un *framework* amb un conjunt de funcions que pretén optimitzar el procés de la creació de models predictius. Aquest paquet conté eines per a:

- Divisió del conjunt de dades.
- Pre-processament de dades.
- Selecció d´atributs.
- *Model tunning*[9] mitjançant remostreig.
- Estimació de la importància de les variables.

En primer lloc, caldrà instal·lar el paquet des del repositori CRAN:

```
install.packages("caret", dependencies = TRUE)
```

A més, ens caldrà instal.lar els següents paquets:

- El paquet `RWeka` que implementa l´algoritme C4.5.
- El paquet `C50` es tracta d´una implementació més moderna de l´algorisme ID3.
- El paquet `rpart` que implementa el mètode CART.
- El paquet `randomForest` que implementa l´agoritme de "Boscos aleatoris"[10].

---

[8] Per a més informació: **https://topepo.github.io/caret/index.html**

[9] Procés que consisteix en optimitzar els paràmetres del model amb l´objectiu que l´algoritme obtingue el millor rendiment.

[10] De l`anglés *Random Forest*. Per a més informació :**https://es.wikipedia.org/wiki/Random_forest**

```
install.packages(c("RWeka", "C50", "rpart", "randomForest"))
```

Separació de dades: Conjunt d´entrenament i prova:

En aquest apartat, dividiren el conjunt de dades en dos subconjunts:

- Conjunt d´entrenamet: Un subconjunt per a entrenar el model.
- Conjunt de prova: Un subconjunt per a provar el model entrenat.

L´objectiu en aquesta tasca es dividir el conjunt de dades de la següent manera:

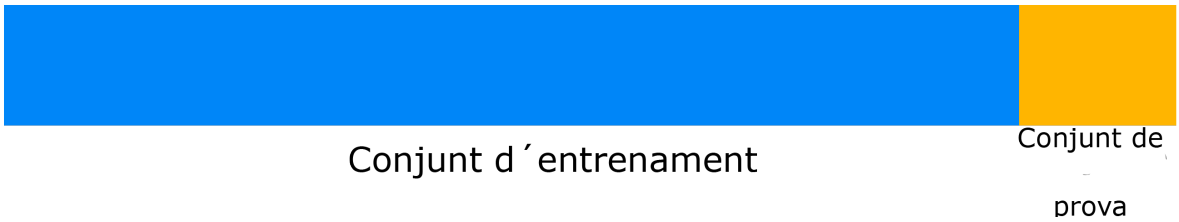

Figura 1. Divisió d´un conjunt de dades en un conjunt d´entrenament i un de prova.

Cal que ens assegurem que el conjunt de prova reuneixi les següents dos condicions:

- Que sigui prou gran com per generar resultats significatius des del punt de vista estadístic.
- Que sigui representatiu de tot el conjunt de dades. En altres paraules, no triar un conjunt de prova amb característiques diferents al del conjunt d'entrenament.

Si suposem que el conjunt de prova reuneix aquestes dues condicions, el nostre objectiu és crear un model que generalitzi les dades noves de forma correcta. En altres paraules, hem de aconseguir un model que no sobreajusti (en àngles, *overfitting*) les dades d'entrenament.

La funció `createDataPartition` ens permetra crear els subconjunts de dades. Per exemple, per a crear una divisió de un 80/20% del conjunt de dades `tickets_client`:

```
# Carreguem el paquet
library(caret)
set.seed(1234)
# Creem el conjunt d´entrenament i el de prova
inTrain <- createDataPartition(tickets_client$FREQCOMPRA, p = 0.8, list = FALSE)
training <- tickets_client[inTrain, ]
testing <- tickets_client[-inTrain, ]
```

A continuació podem comprovar que hem obtingut un conjunt de entrenament de 2606 observacions:

```
dim(training)
```

```
## [1] 3140   13
```

Classificació amb CART

Tot seguit clasificarem de nou les dades d´entrenament, però aquest cop utilitzarem l´algoritme CART:

```
# Carreguem el framework `caret`
library(caret)
# Execució  model CART
modelFitCART <- train(FREQCOMPRA ~ .,
                      data = training,
                      method = "rpart")
```

En aquet cas i amb l´ajuda del paquet `rattle` podem obtindre el gràfic de l´arbre de decisió:

```
# Carreguem la llibreria `rattle`
library(rattle)
# Obtenim un gràfic de l´arbre
fancyRpartPlot(modelFitCART)
```

PART IV Regles d´associació

PART V Conclusions i Recomanacions al Client

Bibliografia

[1] Daniel T. Larouse, Chantal D. Larouse: Data Mininig and Predictive Analytics.USA, John Wiley & Sons,2015,ISBN 978-1-118-11619-7

[2] Jordi Gironés Roig, Jordi Casas Roma, Julià Minguillón Alfonso, Ramon Caihuelas Quiles : Minería de Datos: Modelos y Algoritmos. Barcelona, Editorial UOC, 2017, ISBN: 978-84-9116-904-8.

[3] Jiawe Han, Michellie Chamber & Jian Pei: Data mining : concepts and techniques. 3º Edition. USA, Editorial Elsevier, 2012, ISBN 978-0-12-381479-1